

Clasificación de Cardiotocografías Fetales: un Estudio Comparativo de Regresión Logística, SVM, Árboles de Decisión y KNN bajo Validación Cruzada y Bootstrap

Josua Zevallos

Maestría en Inteligencia Artificial
Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú

Pedro Caycho

Maestría en Inteligencia Artificial
Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú

Marcos Morales

Maestría en Inteligencia Artificial
Universidad de Ingeniería y Tecnología (UTEC)
Lima, Perú

Abstract—La cardiotocografía (CTG) es la prueba más utilizada para monitorear el bienestar fetal, pero su interpretación está sujeta a variabilidad inter-observador. En este trabajo se compara el desempeño de cuatro algoritmos clásicos de aprendizaje supervisado — Regresión Logística, Máquinas de Vectores de Soporte (SVM), Árboles de Decisión y K-Vecinos Más Cercanos (KNN)— sobre un conjunto de 1998 CTG etiquetadas como Normal, Sospechosa o Patológica. Se utiliza validación cruzada estratificada de 5 pliegues para la selección de hiperparámetros y bootstrap con 500 réplicas para estimar el error de generalización mediante el estimador .632. Como el conjunto presenta un fuerte desbalance (77.8 %, 14.0 % y 8.2 % por clase), todos los resultados se reportan en términos de Precisión, Recall y F1 macro-promediados, evitando el sesgo del *accuracy*. El Árbol de Decisión con `min_samples_split=10` obtiene el mejor desempeño ($F1_{.632}=0.897$, $F1\text{-macro}=0.878$ en el conjunto de prueba reservado, $accuracy=92.33\%$), superando consistentemente a SVM-RBF, KNN y Regresión Logística. Se incluye la matriz de confusión porcentual sobre el conjunto de prueba y se discute por qué la clase *Sospechoso* concentra la mayor parte de los errores.

Index Terms—cardiotocografía, clasificación multiclase, validación cruzada, bootstrap, datasets desbalanceados, SVM, árboles de decisión

I. INTRODUCCIÓN

La cardiotocografía (CTG) registra simultáneamente la frecuencia cardíaca fetal (FHR) y las contracciones uterinas y constituye la principal herramienta para evaluar el bienestar fetal durante el embarazo y el trabajo de parto. A pesar de su uso masivo, múltiples estudios han documentado una alta variabilidad inter- e intra-observador en la interpretación clínica de los trazos, lo que motiva la aplicación de técnicas de aprendizaje automático que provean diagnósticos asistidos más reproducibles [1].

Trabajo desarrollado para el curso de Aprendizaje de la Máquina, Maestría en Inteligencia Artificial, Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú.

El conjunto de datos *Cardiotocography* originalmente descrito por Ayres-de-Campos *et al.* [1] se ha convertido en una referencia estándar en la comunidad de aprendizaje automático médico. Cada registro está representado por 21 características numéricas extraídas automáticamente del trazo (línea base, aceleraciones, variabilidad a corto y largo plazo, etc.) y una etiqueta clínica de tres niveles: Normal, Sospechoso y Patológico. Esta etiquetación es *intrínsecamente desbalanceada*: la mayoría de los embarazos transcurren sin complicaciones, por lo que cualquier modelo entrenado debe ser evaluado con métricas robustas al desbalance.

El presente trabajo aborda exhaustivamente la pregunta: ¿cuál de los cuatro modelos clásicos — Regresión Logística, SVM, Árboles de Decisión y KNN— ofrece el mejor compromiso entre precisión y capacidad de generalización para clasificar CTG fetales? Para responderla:

- Se preprocesan 1998 CTG etiquetadas, se reserva el 15 % para prueba final mediante muestreo estratificado y se aplica escalado estándar a los modelos sensibles a la escala.
- Se buscan hiperparámetros con `GridSearchCV` sobre validación cruzada estratificada de 5 pliegues, optimizando F1 macro-promediado.
- Para cada mejor configuración se realiza una validación adicional mediante *bootstrap* con 500 réplicas, reportando el estimador .632 y un intervalo de confianza al 95 % basado en la distribución *out-of-bag*.
- Se evalúa el modelo ganador en el conjunto de prueba reservado y se presenta la matriz de confusión porcentual por clase.

La semilla `numpy.random.seed(42)` [7] se utiliza en todos los procesos estocásticos para garantizar reproducibilidad.

El código fuente está disponible públicamente¹ en formato Python+scikit-learn.

II. MODELOS

Esta sección resume brevemente los cuatro modelos comparados, centrándose en los aspectos relevantes para clasificación multiclase.

A. Regresión Logística

Generaliza el modelo logístico binario al caso multiclase mediante una función *softmax* sobre los logits lineales:

$$P(y = k | \mathbf{x}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x} + b_k)}{\sum_{j=1}^K \exp(\mathbf{w}_j^\top \mathbf{x} + b_j)}. \quad (1)$$

Se ajusta minimizando el negativo de la log-verosimilitud con regularización ℓ_2 controlada por la inversa C . Es un modelo lineal, calibrado y rápido, pero no captura interacciones no lineales entre variables sin ingeniería previa.

B. Máquinas de Vectores de Soporte (SVM)

Maximiza el margen entre clases. Para el caso no lineal se utiliza el truco del kernel, en particular el kernel gaussiano (*Radial Basis Function*, RBF):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2). \quad (2)$$

La generalización multiclase se realiza por *one-vs-rest*. Los hiperparámetros más influyentes son C , que regula el compromiso margen/error, y γ , que controla el ancho del kernel. SVM es altamente sensible a la escala de las variables.

C. Árboles de Decisión

Particionan recursivamente el espacio de características seleccionando, en cada nodo, la división que más reduce la impureza Gini:

$$\text{Gini}(t) = 1 - \sum_{k=1}^K p_k^2. \quad (3)$$

Son interpretables, no requieren escalado y manejan naturalmente múltiples clases, pero tienden al sobreajuste si no se regularizan vía profundidad máxima, número mínimo de muestras por hoja o poda.

D. K-Vecinos Más Cercanos (KNN)

Método *lazy* que clasifica una muestra como la moda de las etiquetas de sus k vecinos más cercanos según alguna distancia. Es no paramétrico y sufre la maldición de la dimensión con muchas variables irrelevantes; al igual que SVM requiere variables estandarizadas. Los hiperparámetros relevantes son k , el esquema de ponderación (uniforme o por inversa de distancia) y la métrica (Euclidiana o Manhattan).

¹Repositorio: https://github.com/jpzevallos/ML_mini_proyecto




Fig. 1. Distribución de las clases en el conjunto de datos.

III. EXPERIMENTOS

A. Conjunto de datos y preprocesamiento

El conjunto contiene 1998 CTG con 21 características numéricas² (línea base LB, aceleraciones AC, movimientos fetales FM, contracciones uterinas UC, desaceleraciones DL/DS/DP, variabilidad a corto/largo plazo ASTV/MSTV/ALTV/MLTV, ancho del histograma Width, mínimo, máximo, modas, media, mediana, varianza y tendencia) y la etiqueta CLASE. No se encontraron valores faltantes.

La distribución de clases es marcadamente desbalanceada (Fig. 1). Para preservar esta proporción en cada partición se utilizó muestreo estratificado: 1698 registros (85 %) para entrenamiento/validación y 300 (15 %) reservados como conjunto de prueba final. Las 21 características se estandarizaron a media cero y varianza uno para la Regresión Logística, SVM y KNN; para el Árbol de Decisión se utilizaron las variables originales (los árboles son invariantes a transformaciones monótonas).

La Fig. 2 muestra que existen bloques de variables fuertemente correlacionadas, en particular entre Mode, Mean y Median, y entre los descriptores de variabilidad. Esto sugiere que un modelo con regularización o capacidad de selección implícita de variables (árboles, SVM con ℓ_2) podría tener ventaja sobre KNN, que es sensible a variables redundantes.

B. Protocolo de validación

La selección de hiperparámetros se realizó con GridSearchCV sobre validación cruzada estratificada de 5 pliegues. La métrica de optimización fue F1 macro-promediado para penalizar igualmente errores en cada clase a pesar del desbalance. La Tabla I resume los *grids* explorados.

Una vez seleccionados los mejores hiperparámetros, se realizó un segundo procedimiento de validación más robusto: *bootstrap* con 500 réplicas. En cada réplica se muestreó con reemplazo el conjunto de entrenamiento, el modelo se ajustó

²El enunciado del proyecto menciona un vector de 20 dimensiones; el archivo de datos provisto contiene en realidad 21 columnas predictoras más la etiqueta. Se utilizaron las 21 características disponibles sin descartar ninguna, por consistencia con los datos reales entregados.




Fig. 2. Matriz de correlación de Pearson entre las 21 características. Se observa correlación alta entre los estadísticos del histograma (Mode, Mean, Median).

TABLE I
ESPACIOS DE BÚSQUEDA PARA CADA MODELO

Modelo	Hiperparámetros explorados
LogReg	$C \in \{0.01, 0.1, 1, 10\}$; $class_weight \in \{None, balanced\}$
SVM	$C \in \{0.1, 1, 10\}$; $kernel \in \{lin, RBF\}$; $\gamma \in \{scale, 0.1\}$; $class_weight=balanced$
Árbol	$max_depth \in \{None, 5, 10, 20\}$; $min_samples_split \in \{2, 5, 10\}$; $class_weight \in \{None, balanced\}$
KNN	$k \in \{3, 5, 7, 11, 15\}$; $weights \in \{uniform, distance\}$; $metric \in \{Euclid, Manh\}$

sobre la muestra y se evaluó tanto *in-bag* como sobre las observaciones no muestreadas (*out-of-bag*, OOB, $\sim 37\%$ del conjunto en cada réplica). El error final se reportó mediante el estimador .632 de Efron y Tibshirani [2]:

$$\widehat{err}_{.632} = 0.368 \cdot \widehat{err}_{in} + 0.632 \cdot \widehat{err}_{OOB}. \quad (4)$$

Esta combinación mitiga el sesgo optimista del error *in-bag* y el sesgo pesimista de la OOB. Adicionalmente se construyó un intervalo de confianza al 95 % mediante los percentiles 2.5 y 97.5 de la distribución de F1-macro OOB.

C. Resultados de la búsqueda de hiperparámetros

La Tabla II resume las dos mejores configuraciones por modelo encontradas en la validación cruzada (la lista completa, con las 64 combinaciones evaluadas, está en el repositorio como `grid_search_full.csv`).

Tres observaciones merecen comentario. *Primero*, en los árboles, agregar `class_weight=balanced` no mejoró el

TABLE II
TOP-2 HIPERPARÁMETROS POR MODELO (F1-MACRO EN CV DE 5 PLIEGUES, $\pm$ DESVIACIÓN ESTÁNDAR)

Modelo	Hiperparámetros	F1-macro
LogReg	$C = 10$, sin pesos	0.789 ± 0.030
	$C = 1$, sin pesos	0.788 ± 0.027
SVM	$C = 10$, RBF, $\gamma = 0.1$, balanced	0.844 ± 0.027
	$C = 10$, RBF, $\gamma=scale$, balanced	0.838 ± 0.025
Árbol	$min_split=10$, sin límite	0.882 ± 0.025
	$min_split=5$, sin límite	0.872 ± 0.031
KNN	$k = 3$, distancia, Manhattan	0.838 ± 0.023
	$k = 3$, distancia, Euclidiana	0.831 ± 0.024

TABLE III
BOOTSTRAP (500 RÉPLICAS) PARA LOS MEJORES HIPERPARÁMETROS

Modelo	F1 _{in}	F1 _{OOB}	F1 _{.632}	IC 95 % (OOB)
LogReg	0.840	0.790	0.809	[0.747, 0.830]
SVM	0.978	0.840	0.891	[0.802, 0.877]
Árbol	1.000	0.852	0.897	[0.807, 0.891]
KNN	1.000	0.819	0.886	[0.777, 0.858]

F1-macro a pesar del desbalance: el reponderamiento favorecería tanto a la clase minoritaria como introducía ruido en la mayoritaria. *Segundo*, en SVM y KNN el escalado fue crítico: sin estandarización, ambos colapsan a F1-macro por debajo de 0.7 (no reportado por brevedad). *Tercero*, $k = 3$ con ponderación por inversa de distancia superó consistentemente a k mayores, indicando que las CTG patológicas se concentran en regiones locales del espacio de características.

D. Validación por bootstrap

La Tabla III muestra los estimadores .632, los promedios *in-bag* y OOB, y los intervalos de confianza al 95 %.

El estimador .632 sitúa al Árbol de Decisión en primer lugar ($F1_{.632} = 0.897$), seguido muy de cerca por SVM (0.891) y KNN (0.886). La Regresión Logística queda claramente por debajo (0.809), reflejando su limitación para capturar las fronteras de decisión no lineales entre clases. Es notable que SVM, KNN y Árbol exhiben F1 *in-bag* cercanos a uno, indicando alta capacidad de ajuste; sin embargo la brecha con el error OOB no es excesiva, indicando que el sobreajuste está controlado por los hiperparámetros seleccionados.

E. Métricas por clase

Dada la naturaleza desbalanceada del problema, es indispensable examinar las métricas por clase. La Tabla IV reporta Precisión, *Recall* y F1 promedio (sobre los 5 pliegues de CV) para cada clase y modelo.

La conclusión es robusta: *en todos los modelos, la clase intermedia (Sospechoso) concentra los peores resultados*. Esto es esperable clínicamente: el solapamiento entre Sospechoso y los extremos (Normal y Patológico) es inherente a la propia definición del criterio diagnóstico, que utiliza *Sospechoso*

TABLE IV
PRECISIÓN/RECALL/F1 POR CLASE (PROMEDIO EN CV)

Modelo	Clase	Prec.	Recall	F1
LogReg	Normal	0.929	0.953	0.940
	Sospechoso	0.722	0.611	0.660
	Patológico	0.804	0.731	0.766
SVM	Normal	0.953	0.954	0.953
	Sospechoso	0.756	0.708	0.731
	Patológico	0.804	0.879	0.838
Árbol	Normal	0.951	0.964	0.957
	Sospechoso	0.793	0.738	0.764
	Patológico	0.935	0.929	0.932
KNN	Normal	0.947	0.965	0.956
	Sospechoso	0.766	0.674	0.717
	Patológico	0.829	0.851	0.840




Fig. 3. F1-macro por modelo bajo distintos esquemas de evaluación. Las barras de error en CV representan ± 1 desviación estándar entre pliegues.

como una categoría residual. La Fig. 3 resume gráficamente el F1-macro por método de validación.

F. Evaluación final en el conjunto de prueba

Siguiendo el criterio del estimador .632, el modelo elegido es el **Árbol de Decisión** ($\text{min_samples_split}=10$, sin límite de profundidad). Reentrenado sobre la totalidad del conjunto de entrenamiento (1698 registros) y evaluado sobre los 300 registros reservados, obtiene:

- **Accuracy** = 92.33 %.
- **F1-macro** = 0.878.
- Precisión/Recall/F1 por clase: Normal 0.945/0.957/0.951; Sospechoso 0.795/0.738/0.765; Patológico 0.917/0.917/0.917.

La matriz de confusión porcentual se presenta en la Fig. 4. Los aciertos por clase son: Normal 95.7 %, Sospechoso 73.8 %, Patológico 91.7 %. El error principal proviene de la clase Sospechoso: 26.2 % de las CTG sospechosas se clasificaron como Normales. Clínicamente esto representa un falso negativo blando (un caso que requiere monitoreo adicional se considera saludable), un tipo de error que en un sistema de despliegue podría mitigarse calibrando un umbral específico o




Fig. 4. Matriz de confusión porcentual del Árbol de Decisión sobre el conjunto de prueba ($n=300$). Filas: clase real, columnas: predicción.

utilizando el modelo únicamente como filtro preliminar de los casos más claros (Normales y Patológicos).

G. Predicción sobre el conjunto de test externo

Finalmente, el Árbol de Decisión fue reentrenado sobre la totalidad de los 1998 registros etiquetados y aplicado a los 127 registros del conjunto de test externo (pestaña 2 del archivo provisto), que no contiene etiquetas de clase. La distribución de las predicciones resultante fue: 99 registros clasificados como Normal (78.0 %), 14 como Sospechoso (11.0 %) y 14 como Patológico (11.0 %). Esta proporción es coherente con la distribución observada en los datos de entrenamiento (77.8 %, 14.0 %, 8.2 %), lo cual es un indicador favorable de que el modelo no está produciendo predicciones sesgadas. Las predicciones individuales se encuentran en el archivo `predicciones_test_127.csv` del repositorio.

IV. CONCLUSIONES

Se compararon cuatro algoritmos clásicos de clasificación sobre 1998 cardiocografías fetales, utilizando un protocolo robusto basado en validación cruzada estratificada de 5 pliegues seguida de *bootstrap* con 500 réplicas. Las conclusiones principales son:

- 1) El **Árbol de Decisión** fue el mejor modelo, con $F1_{.632} = 0.897$ y F1-macro de 0.878 sobre el conjunto de prueba reservado. Su *accuracy* del 92.33 % supera el *baseline* trivial (predecir siempre Normal) del 77.8 % por casi 15 puntos.
- 2) SVM-RBF y KNN obtuvieron desempeños competitivos ($F1_{.632} = 0.891$ y 0.886 respectivamente), confirmando que estructuras locales y no lineales son centrales para este problema. La Regresión Logística, modelo lineal, quedó claramente rezagada ($F1_{.632} = 0.809$).
- 3) En todos los modelos, la clase *Sospechoso* concentró los errores. Esto es consistente con su rol clínico

como categoría intermedia y sugiere que técnicas focalizadas en frontera (*ensembles*, *cost-sensitive*, o reformulación como dos problemas binarios Normal-vs-Anormal seguidos por Sospechoso-vs-Patológico) podrían aportar mejoras significativas.

- 4) Reportar exclusivamente *accuracy* hubiera sido engañoso: en este dataset un clasificador trivial supera el 77 %. Las métricas macro-promediadas por clase, combinadas con la matriz de confusión, son indispensables.

Como trabajo futuro se propone (i) evaluar conjuntos como *Random Forest* y *Gradient Boosting* bajo el mismo protocolo, (ii) aplicar técnicas de re-muestreo dirigidas (SMOTE, ADASYN) que ataquen específicamente la frontera Sospechoso/resto, y (iii) construir umbrales operativos clínicamente significativos sobre las probabilidades calibradas.

REFERENCES

- [1] D. Ayres-de-Campos, J. Bernardes, A. Garrido, J. Marques-de-Sá, and L. Pereira-Leite, "SisPorto 2.0: a program for automated analysis of cardiotocograms," *J. Matern. Fetal Med.*, vol. 9, no. 5, pp. 311–318, 2000.
- [2] B. Efron and R. Tibshirani, "Improvements on cross-validation: the .632+ bootstrap method," *J. Amer. Statist. Assoc.*, vol. 92, no. 438, pp. 548–560, 1997.
- [3] L. Breiman, J. Friedman, R. Olshen, and C. Stone, *Classification and Regression Trees*. Chapman & Hall, 1984.
- [4] C. Cortes and V. Vapnik, "Support-vector networks," *Mach. Learn.*, vol. 20, no. 3, pp. 273–297, 1995.
- [5] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Trans. Inf. Theory*, vol. 13, no. 1, pp. 21–27, 1967.
- [6] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [7] NumPy Developers, "numpy.random.seed — legacy random state," NumPy Documentation, 2024. [Online]. Available: <https://numpy.org/doc/stable/reference/random/generated/numpy.random.seed.html>